

MINERÍA DE DATOS (MIIA 4200)

Primer semestre de 2026

Profesor: Rafael Amaya Gómez

e-mail: r.amaya29@uniandes.edu.co

Asistente: Sofia Acosta

e-mail: s.acosta112@uniandes.edu.co

Horario: Lunes 18:00 a 20:50

Créditos: 4

Salón: ML-509

DESCRIPCIÓN Y METODOLOGÍA

Uno de los pilares dentro de la analítica de datos, como soporte para la toma de decisiones, es la minería de datos. Esta corresponde con un proceso en donde se extrae y se obtiene información relevante a partir de grandes cantidades de datos. Este curso busca brindarle al estudiante conceptos y técnicas fundamentales en este sentido, cubriendo temáticas ampliamente usadas para herramientas de clasificación, agrupación o predicción.

El curso consta de una clase magistral acompañada de ejercicios prácticos y proyectos en equipo. En los ejercicios, los participantes adquirirán una experiencia inicial en la aplicación de las herramientas de minería de datos a conjuntos de datos realistas. Los proyectos en equipo tienen lugar a lo largo del semestre. En ellos, los estudiantes realizan proyectos de minería de datos usando una base de datos común e informan sobre los resultados de sus proyectos en forma de informe escrito y de presentación oral.

OBJETIVOS

General

Desarrollar competencias en torno a la minería de datos, contemplando el uso y aplicación de herramientas de procesamiento de datos y métodos de clasificación, agrupación o predicción como insumo para soportar la toma de decisiones.

Específicos

- Comprender los conceptos y técnicas básicas de la minería de datos
- Aprender a aplicar técnicas de minería de datos a problemas del mundo real
- Comprender la importancia del preprocesamiento de datos y cómo prepararlos para la minería.
- Aprender a evaluar los resultados de los modelos de minería de datos
- Ser capaz de utilizar herramientas de programación para llevar a cabo tareas de minería de datos.

CONTENIDO DEL CURSO

- **Inicio de clases:** Enero 20
- **Entrega 30% de la nota:** Marzo 27
- **Último día de retiros:** Abril 17
- **Semana de trabajo individual:** Marzo 16 a 21
- **Semana Santa:** Marzo 30 a Abril 05
- **Último día de clase:** Mayo 23
- **Exámenes finales:** Mayo 25 a 30

Sem.	Fecha	Tema	Subtemas/Actividad	Lectura recomendada
2	26/01/2025	Inicio de clases/ Introducción Python y R	Estructura, operadores lógicos, gráficas y análisis exploratorios	Librerías NumPy, Pandas & Matplotlib R Para Ciencia de Datos
3	02/02/2025	Introducción a aprendizaje estadístico	Tipos de aprendizaje, error de predicción, medidas de desempeño Quiz 1	James Capítulo 2
4	09/02/2025	Procesamiento de datos	Limpieza de datos, detección de anomalías, normalización Ejercicio en clase	Han Capítulo 2-3
5	16/02/2025	Reducción de dimensionalidad y selección de atributos	Métodos de PCA, MCA, RFE Taller 1	Husson Cap. 1-3 James Cap.6, Sec. 10.2
6	23/02/2025	Aproximaciones lineales de regresión	Regresión lineal, medidas estadísticas, supuestos	James Capítulo 3
7	02/03/2025	Aproximaciones no lineales de regresión	Regresión polinómica, GAMS, GWR Quiz 2	James Capítulo 7
8	09/03/2025	Problema de clasificación I	Regresión logística, FDA, KNN Ejercicio en clase	James Capítulo 4
	16/03/2025 21/03/2025	SEMANA DE RECESO		
9	*23/03/2025*	Problema de clasificación II	Máquinas de soporte vectorial SVM Taller 2	James Capítulo 9
	30/03/2025 05/04/2025	SEMANA SANTA		
10	06/03/2025	Herramientas de clustering	K-medias, K-modas, clustering jerárquico	James Capítulo 12 Han Capítulo 10
11	13/04/2025	Árboles de decisión	Árboles de regresión, clasificación Quiz 3	James Capítulo 8
12	20/04/2025	Evaluación y selección de modelos	Métricas de selección, remuestreo, validación cruzada, bootstrap, ROC Ejercicio en clase	James Capítulo 5, Sección 6.1.3
13	27/04/2025	Aprendizaje por ensamblaje	Random forest, boosting Taller 3	James Capítulo 8.2 Han Capítulo 8.6
14	04/05/2025	Introducción a minería de texto	Análisis de sentimiento, modelamiento tópico, LDA	
15	11/05/2025	Presentación Proyecto		
16	18/05/2025	Proyecto: Trabajo individual	FESTIVO	
E.F.	25/05/2025 30/05/2025	Sustentación Proyecto		

***Festivo*.** La clase de la sesión 8 se reprogramará en otro horario acordado entre los estudiantes y el profesor

Es importante realizar la lectura del tema correspondiente a cada módulo durante cada una de las semanas del semestre.

METODOLOGÍA

El curso se llevará a cabo a través de las siguientes actividades:

- **Clases magistrales:** a cargo del profesor. Se expondrá e ilustrará los temas que contemplan el curso.
- **Lecturas anticipadas a las clases magistrales:** a cargo de los estudiantes. Se deberá leer antes de cada clase el tema correspondiente.
- **Ejercicios en clase y actividades prácticas:** el estudiante, resolverá diversos problemas donde se aplicarán los temas del curso, el desarrollo de estos se hará dentro de la clase.
- **Talleres:** el estudiante, resolverá diversos problemas donde se aplicarán los temas del curso, el desarrollo de estos se hará fuera de la clase.
- **Proyecto:** se resolverá en grupos de hasta cuatro personas para reforzar los temas vistos en clase.

EVALUACIÓN

- ✓ 40% Talleres
- ✓ 15% Ejercicios en clase
- ✓ 15% Quices
- ✓ 30% Proyecto

Nota:

- ✓ No se aceptarán tareas, informes, trabajos y en general cualquier documento solicitado, fuera del horario estipulado por el profesor.
- ✓ La resolución de dudas se atenderá a través del foro del curso únicamente. La comunicación por correo será limitada y utilizada en caso extremo.

NOTA FINAL:

El Comité Directivo, en su sesión 63-12 del 14 de noviembre de 2012, aprobó que, a partir del 2013, las calificaciones definitivas de las materias serán numéricas de uno punto cinco (1.5) a cinco punto cero (5.0), en unidades, décimas y centésimas. Por tal motivo la nota **NO** será aproximada y tendrá dos cifras decimales.

BIBLIOGRAFÍA

- JAMES G., WITTEN D., HASTIE T., TIBSHIRANI R., TAYLOR J., **An introduction to statistical Learning with Applications in Python**, Springer, 2023
- HAN J., KAMBER M., PEI J., **Data Mining- Concepts and Techniques**, Morgan Kaufmann (Elsevier), Third Edition, 2012
- WICKHAM H., ÇETINKAYA-RUNDEL M., GROLEMUND G., **R for Data Science**, O'Reilly, Second edition, 2023, ISBN 978-1-492-09740-2.
 - R Para Ciencia de Datos, disponible en <https://es.r4ds.hadley.nz/>
- HUSSON F., LÊ S., PAGÈS J. **Exploratory Multivariate Analysis by Example Using R**, CRC Press, 2017
- KWARTLER T. **Text Mining in Practice with R**, Wiley, 2017